

Identificação de tecnologias emergentes a partir de dados de patentes usando ML na área da construção civil

Dimitri Prado
Universidade de São Paulo
dimitriprado@usp.br

Luis Henrique Moraes
Universidade de São Paulo
luishmoraes@usp.br

Pedro Oliveira Fernandes
Universidade de São Paulo
pedro.oliveiraf@usp.br

Rodrigo Lyusei Suguimoto
Universidade de São Paulo
rodrigo.lyusei@usp.br

Resumo

A identificação precoce de tecnologias emergentes constitui um desafio para setores consolidados como o da construção civil, onde métodos tradicionais de análise podem ser insuficientes. Este estudo propõe uma metodologia para a identificação de tecnologias emergentes no setor da construção civil brasileira, combinando modelagem de tópicos (Latent Dirichlet Allocation - LDA) e aprendizado de máquina (ML) para analisar dados de patentes. Para isso, inicialmente, é realizada a coleta e o pré-processamento de patentes brasileiras da base de dados Lens.org. Em seguida, o modelo LDA é aplicado para identificar temas tecnológicos latentes no corpus de documentos. A "emergência" de cada tema é então quantificada por meio de uma abordagem híbrida, que pondera a probabilidade do tópico estar presente em cada patente por uma combinação de suas citações para frente (forward citations), número de inventores e número de reivindicações; essa pontuação híbrida serve como critério para ranquear e identificar os temas tecnológicos de maior potencial. Sendo assim, é possível visualizar as patentes associadas a esses tópicos de destaque, identificando tecnologias emergentes e as tendências futuras do setor.

Palavras-chave: Construção Civil; Patentes; Tecnologias Emergentes; Machine Learning

1 Introdução

O setor da construção civil tem importância tanto no aspecto social quanto no econômico, sendo uma das áreas que mais contribui para a geração de empregos e o aquecimento da economia. Sua robustez foi demonstrada durante a pandemia de COVID-19, quando foi considerado um serviço essencial e conseguiu manter a estabilidade, com a maioria das empresas atingindo ou superando os resultados esperados (Colares et al., 2021).

Porém, a área da construção civil enfrenta um grave problema de sustentabilidade, sendo o maior consumidor mundial de matérias-primas e exercendo enorme pressão sobre os recursos naturais. De acordo com Munaro e Tavares (2022), o setor é responsável por uma parcela significativa dos impactos ambientais globais, gerando até 35% dos resíduos em aterros, respondendo por 36% do uso final de energia e 39% das emissões globais de dióxido de carbono. Diante disso, observamos a necessidade de mudança nos padrões de produção e consumo, realizando a transição para uma economia circular (EC).

O problema surge quando essa transição é dificultada pelo fato de o setor ser historicamente conservador e tecnologicamente atrasado. A própria complexidade da sua cadeia de valor e a falta de mão de obra qualificada para novas ferramentas representam barreiras. Eventos recentes, como a própria pandemia, acabaram estimulando a necessidade de uma transformação digital, impulsionando o interesse em tecnologias como inteligência artificial, Big Data, impressão 3D e o uso de drones, que já demonstram seu valor em áreas correlatas (Colares et al., 2021).

Assim, vemos que a inovação tecnológica é fundamental para a competitividade e o desenvolvimento sustentável. Para indústrias consolidadas, como a da construção civil, a capacidade de identificar tecnologias emergentes de forma antecipada é um diferencial estratégico crucial, permitindo que as empresas se adaptem, lancem novos produtos e otimizem processos existentes (Choi et al., 2021). A identificação de tendências promissoras possibilita o direcionamento de investimentos em pesquisa e desenvolvimento para áreas com maior potencial de retorno, garantindo uma vantagem competitiva (Lee et al., 2018).

Diante desse desafio, a literatura recente tem explorado modelos computacionais para superar as limitações dos métodos tradicionais. Uma vertente promissora é o uso de modelos de tópicos, como o Latent Dirichlet Allocation (LDA), que permite descobrir estruturas temáticas latentes em grandes volumes de texto, indo além da simples contagem de palavras-chave e identificando os conceitos tecnológicos subjacentes em um corpus de patentes (Ranaei & Suominen, 2017). Outros estudos argumentam que a identificação de "novidade radical" (Zhou et al., 2021), ou seja, de patentes com pouca similaridade com o conhecimento existente, é um indicador mais preciso de tecnologias verdadeiramente disruptivas. Essa visão é reforçada pela necessidade de avaliar o potencial de uma tecnologia sob múltiplas dimensões, combinando tanto seu impacto tecnológico, frequentemente medido por citações futuras, quanto seu impacto social (Zhou et al., 2021).

Avançando nessa linha, pesquisadores têm proposto a combinação de múltiplos indicadores de patentes para criar uma avaliação mais robusta da qualidade ou do potencial de uma invenção (Erdogan et al., 2022; Lee et al., 2018). A lógica é que características intrínsecas da patente, disponíveis no momento de sua publicação — como o escopo da proteção (número de reivindicações), a intensidade da colaboração (número de inventores) e a ligação com a ciência (referências

não-patente) — podem servir como sinais precoces de seu futuro impacto (Lee et al., 2018). Essa abordagem multifatorial busca construir uma métrica de "qualidade" ou "potencial" que seja mais preditiva e menos dependente do tempo do que as citações isoladas (Erdogan et al., 2022).

Este estudo se insere nesse contexto e propõe um framework metodológico para a identificação de tecnologias emergentes na construção civil brasileira, que integra a modelagem de tópicos com uma métrica híbrida de potencial de emergência. O objetivo é desenvolver um método que não apenas identifique os temas tecnológicos em ascensão, mas que também os classifique com base em um indicador composto, oferecendo uma ferramenta mais robusta e prospectiva para a tomada de decisão estratégica no setor.

2 Trabalhos Correlatos

A análise de patentes tornou-se uma fonte importante para rastrear tendências tecnológicas e identificar inovações emergentes. Métodos tradicionais são úteis, mas apresentam limitações, como subjetividade, dificuldade em processar grandes volumes de dados e ambiguidade de palavras-chave (Beatto & Back, 2022; Choi et al., 2021; Ranaei & Suominen, 2017). Nesse cenário, a análise de dados e o aprendizado de máquina (ML) vêm transformando a prospecção tecnológica, permitindo uma transição de análises retrospectivas para abordagens preditivas (Erdogan et al., 2022; Kreuchauff & Korzinov, 2017; Lee et al., 2018; Zhou et al., 2021).

Um estudo relacionado à nossa pesquisa é o de Choi et al. (2021). Os autores propõem uma abordagem híbrida que combina percepções de especialistas com dados de patentes para identificar tecnologias promissoras. Eles utilizam aprendizado semi-supervisionado e ativo, aplicando classificadores como Random Forest (RF), Support Vector Machine (SVM) e Extreme Gradient Boosting (XGBoost) no setor de baterias para veículos elétricos. Os resultados mostram que a incorporação do conhecimento de especialistas melhora significativamente a acurácia das previsões. Nosso estudo converge com este trabalho, pois também empregamos RF e SVM para a classificação de patentes no setor da construção civil.

O trabalho de Kyebambe et al. (2017) propõe uma abordagem que considera a limitação crítica da escassez de dados históricos rotulados para o treinamento de classificadores supervisionados. O método introduz um algoritmo de rotulagem de dados que utiliza a criação de novas classes no sistema de Classificação de Patentes dos Estados Unidos (USPC) em um ano $T + 1$ para rotular agrupamentos de patentes no ano T como Tecnologias Emergentes (ET) ou Não Emergentes (NET). Distintamente das abordagens anteriores que dependem de citações futuras (as quais sofrem um lapso temporal significativo), Kyebambe et al. (2017) empregam citações passadas para derivar os preditores do estudo.

No campo do Processamento de Linguagem Natural (NLP) para prospecção, Ranaei e Suominen (2017) exploraram o uso de modelos preditivos não supervisionados para detectar padrões de emergência a partir do conteúdo textual de resumos de patentes. Empregando o Latent Dirichlet Allocation (LDA) e o Dynamic Topic Modeling (DTM) em um grande conjunto de patentes relacionadas a veículos, os autores buscaram superar as limitações dos métodos baseados em contagem. Embora o LDA seja inerentemente alheio à dinâmica temporal, a informação do ano de publicação de cada patente foi introduzida posteriormente, permitindo a análise do crescimento da

importância relativa de cada tópico ao longo do tempo. Essa abordagem identificou anos de dinamismo significativo e revelou a emergência de tópicos como materiais de folha (sheet materials) e compostos químicos de hidrogênio em 1991.

Outros trabalhos relevantes reforçam essa direção. Lee et al. (2018) aplicam redes neurais e RF para detectar tecnologias emergentes por meio de indicadores de patentes. Kwon e Geum (2020) utilizam SVM e RF para identificar invenções promissoras. Já Mohammadi et al. (Mohammadi et al., 2024) exploram redes de colaboração em patentes para identificar tendências tecnológicas. Em conjunto, esses estudos demonstram como técnicas de ML podem mapear ecossistemas de patentes, identificar tecnologias emergentes e antecipar inovações.

3 Fundamentos Teóricos

3.1 Mineração de texto

A Mineração de Texto (do inglês Text Mining) pode ser definida como o processo computacional de descobrir conhecimento e extrair informações de alta qualidade a partir de grandes volumes de dados textuais. O desafio central dessa área é que os textos, como os encontrados em documentos de patentes, são dados "não estruturados", ou seja, não estão organizados em um formato de banco de dados tradicional, o que impede sua análise direta por máquinas. O objetivo da mineração de texto é, portanto, transformar esses textos livres em dados estruturados e interpretáveis.

O processo de mineração é tipicamente dividido em etapas sequenciais. Inicia-se pelo pré-processamento, que visa "limpar" e padronizar os dados brutos através de tarefas como a tokenização (a quebra do texto em unidades menores), a remoção de stopwords (palavras muito frequentes e com baixo valor semântico) e a normalização (redução das palavras às suas formas radicais). Em seguida, os textos limpos são convertidos em uma representação numérica. Modelos clássicos, como o Bag-of-Words (BoW), realizam essa tarefa contando a frequência de cada palavra.

Com os textos em formato vetorial, aplicam-se técnicas de aprendizado de máquina (machine learning) ou estatísticas para, de fato, extrair os padrões. Isso pode envolver a redução de dimensionalidade, essencial para lidar com a alta variabilidade dos dados textuais, ou a aplicação de algoritmos de clusterização para agrupar documentos por similaridade. No contexto deste trabalho, a mineração de texto é a ferramenta-chave para analisar o vasto repositório de patentes, permitindo mapear tendências e identificar inovações emergentes, como demonstrado em Ranaei e Suominen, 2017.

3.1.1 Latent Dirichlet Allocation (LDA)

Dentre as diversas técnicas de mineração de texto, destaca-se a Latent Dirichlet Allocation (LDA), ou Alocação Latente de Dirichlet. O LDA é um modelo de tópicos (topic modeling) probabilístico e generativo, amplamente utilizado para descobrir os temas latentes (ocultos) em uma coleção de documentos (ou corpus).

O LDA apresenta duas premissas fundamentais:

1. Cada documento é visto como uma mistura de múltiplos tópicos, em diferentes proporções

(por exemplo, uma patente de construção pode ser 80% sobre "Novos Compósitos Cimentícios" e 20% sobre "Eficiência Energética").

2. Cada tópico é definido como uma distribuição de probabilidades sobre um conjunto de palavras do vocabulário (o tópico "Novos Compósitos Cimentícios" teria alta probabilidade de gerar palavras como "cimento", "agregado", "resíduo", "resistência" e "fibra").

O LDA não exige que os tópicos sejam definidos previamente pelo pesquisador. O modelo analisa a coocorrência das palavras ao longo de todos os documentos para inferir, estatisticamente, quais grupos de palavras tendem a aparecer juntos, formando assim os tópicos. O nome *Dirichlet* deriva do uso de distribuições de Dirichlet em sua formulação matemática, que são adequadas para modelar as proporções (tanto a distribuição de tópicos por documento quanto a distribuição de palavras por tópico). O LDA permite organizar e resumir grandes volumes de dados textuais em temas coerentes.

3.2 Modelos de Predição Supervisionados

Modelos preditivos são algoritmos de aprendizado de máquina (machine learning) treinados para identificar padrões em dados históricos com o objetivo de prever resultados futuros. O emprego desses modelos é vasto, permitindo, por exemplo, antecipar tendências ou classificar novos dados com base em exemplos passados. O processo de "treinamento" consiste em alimentar o algoritmo com um conjunto de dados para que ele aprenda as relações matemáticas entre as variáveis de entrada (as features) e uma variável de saída.

Neste trabalho, o foco recai sobre o aprendizado supervisionado. Este paradigma de treinamento exige, como pré-requisito, um conjunto de dados previamente rotulado. Isso significa que, para cada amostra (ou tupla) dos dados de treino, o valor da variável de interesse (o rótulo) já é conhecido. O algoritmo, então, aprende a mapear as entradas para a saída correta, generalizando esse aprendizado para prever os rótulos de dados futuros, que não foram usados para o treinamento. Um exemplo de aplicação dessa técnica para análise de patentes pode ser encontrado em Kyebambe et al., 2017.

3.2.1 *Extreme Gradient Boosting (XGBoost)*

O Extreme Gradient Boosting (XGBoost) é um algoritmo de ensemble (conjunto) supervisionado, baseado na técnica de boosting (reforço). Modelos de boosting constroem um aprendiz forte de forma iterativa, através da combinação sequencial de múltiplos aprendizes fracos, que são, tipicamente, árvores de decisão.

Diferente de outros métodos que combinam árvores, como o Random Forest, o XGBoost funciona de maneira aditiva: ele treina uma primeira árvore, avalia seus erros de predição, e então treina a próxima árvore focando especificamente em corrigir as falhas da anterior. O termo Gradient em seu nome deriva do uso do algoritmo de otimização de gradiente descendente (gradient descent), que é utilizado para minimizar a função de perda (o erro de predição) a cada nova árvore adicionada ao modelo. Essa abordagem o torna uma das ferramentas mais eficientes e precisas para problemas de classificação e regressão.

3.2.2 Support Vector Machine (SVM)

O Support Vector Machine (SVM), ou Máquina de Vetores de Suporte, é outro robusto algoritmo de aprendizado supervisionado, classicamente utilizado para tarefas de classificação binária. A intuição central do SVM é encontrar um hiperplano (uma linha, em duas dimensões, ou um plano, em três) que melhor separe os pontos de dados pertencentes a classes opostas em um espaço vetorial.

O melhor hiperplano é definido como aquele que maximiza a margem, ou seja, a distância entre ele e os pontos de dados mais próximos de cada classe. Esses pontos mais próximos, que suportam o hiperplano e definem a margem, são chamados de vetores de suporte. Para lidar com conjuntos de dados que não são linearmente separáveis no espaço original, o SVM emprega o chamado kernel trick (truque do kernel), que projeta os dados em um espaço de dimensão superior onde uma separação linear se torna possível.

3.2.3 Grid Search

A performance de algoritmos como o XGBoost ou o SVM depende de hiperparâmetros: configurações pré-treinamento (como o número de árvores no XGBoost ou o tipo de kernel no SVM) que definem a arquitetura e o comportamento do modelo. A escolha inadequada desses valores pode levar a um baixo desempenho.

Para encontrar a combinação ideal de forma sistemática, utiliza-se a técnica de Grid Search (Busca em Grade), na qual o pesquisador define um conjunto de valores discretos que deseja testar. O Grid Search então executa um processo exaustivo, treinando e avaliando um modelo para cada combinação possível desses valores. Ao final, a combinação de hiperparâmetros que gerar o modelo com os resultados mais precisos, de acordo com uma métrica de avaliação pré-definida, é a escolhida.

3.2.4 Matriz de Confusão

A matriz de confusão é uma ferramenta para avaliar o desempenho de um modelo decisor, ao comparar o valor predito pelo modelo com o valor real de uma tupla. Em um cenário de classificação binária (onde a saída é "Positivo" ou "Negativo"), a matriz é estruturada em quatro quadrantes principais:

- Verdadeiros Positivos (VP): O modelo previu corretamente a classe Positivo.
- Verdadeiros Negativos (VN): O modelo previu corretamente a classe Negativo.
- Falsos Positivos (FP): O modelo previu Positivo, mas a classe real era Negativo.
- Falsos Negativos (FN): O modelo previu Negativo, mas a classe real era Positivo.

A partir desses valores, podemos calcular diferentes métricas que fornecem uma visão mais aprofundada sobre a performance do modelo.

$$1. \text{ Acurácia (Accuracy)} = \frac{VP+VN}{VP+VN+FP+FN}$$

2. Sensibilidade (Recall) = $\frac{VP}{VP+FN}$
3. Precisão (Precision) = $\frac{VP}{VP+FP}$
4. Especificidade (Specifity) = $\frac{VN}{VN+FP}$
5. F-Score = $\frac{2*Recall*Precision}{Recall+Precision}$

4 Metodologia

A metodologia proposta está estruturada para identificar sistematicamente e analisar tecnologias emergentes no setor da construção civil, utilizando dados de patentes brasileiras e técnicas de aprendizado de máquina. Inspirado na abordagem encontrada e Choi et al., 2021, o processo é dividido em três fases macro: (1) Coleta e Pré-Processamento dos Dados, (2) Modelagem e Classificação de Patentes, e (3) Mapeamento do Ecossistema de Inovação.

4.1 Coleta e Pré-Processamento de Dados

Os dados brutos de patentes foram coletados da base de dados Lens.org, uma plataforma que oferece acesso a uma coleção de patentes globais e artigos acadêmicos. A busca foi realizada por meio de uma query booleana, combinando palavras-chave e termos técnicos relevantes para o domínio da construção civil.

A busca foi direcionada aos campos de título e resumo para garantir a relevância dos documentos. Foi aplicado um filtro geográfico para restringir os resultados a patentes depositadas junto a órgãos brasileiros, como o Instituto Nacional da Propriedade Industrial (INPI). Os dados extraídos (autor, ano de depósito, título, resumo, classificações, etc.) foram exportados em formato de planilha para processamento subsequente. Foram coletadas 50000 patentes, seguindo o limite de nossa base.

Os dados não são diretamente utilizáveis pelos algoritmos. Portanto, uma fase de engenharia de atributos será conduzida. A partir de colunas como "nº de inventores", "nº de reivindicações" e do conteúdo textual de "título" e "resumo", serão extraídas e calculadas variáveis preditoras. Inspirado no artigo de referência, estas variáveis podem ser agrupadas em categorias como: características da invenção; características do depositante; características de palavras-chave.

A variável-alvo, que define uma tecnologia como "emergente" ou "promissora", será operacionalizada considerando a data de criação do IPC daquela patente e as palavras-chave que a definem.

4.2 Rotulação de patentes

A determinação de tecnologias promissoras ou emergentes (ETs) é abordada neste estudo como um problema de classificação supervisionada, fundamental para o planejamento tecnológico estratégico. O processo inicia-se com a representação das patentes, na qual o conteúdo textual é utilizado como proxy das características tecnológicas (Ranaei & Suominen, 2017).

Especificamente, empregamos o algoritmo Latent Dirichlet Allocation (LDA) para análise de palavras, seguindo métodos de avaliação tecnológica que utilizam mineração de texto. O LDA, sendo um modelo preditivo, é utilizado para redução de dimensionalidade e extração de tópicos latentes, o que supera as limitações dos modelos tradicionais baseados apenas na contagem de palavras, tratando a ambiguidade na linguagem natural.

A base de dados de patentes foi inicialmente segmentada de acordo com o ano de publicação X para capturar a evolução temporal. Em seguida, o algoritmo LDA foi aplicado iterativamente para cada ano. O número de tópicos K foi variado em testes.

A rotulagem das patentes foi realizada utilizando uma regra objetiva, baseada na premissa de que tecnologias emergentes devem demonstrar coerência e persistência ao longo do tempo. Este procedimento foi inspirado na metodologia de Kyebambe et al. (2017), que emprega a criação de novas classes de classificação de patentes como um indicador de emergência.

O processo de rotulagem para uma patente K (do ano X) exige duas condições. Primeiro, calculamos a similaridade semântica entre uma patente posterior P (do ano $X + 1$) e a patente K . Para isso, consideramos as palavras mais relevantes de cada patente, obtidas a partir dos resultados do LDA, que são fundamentais para análises de similaridade. Depois, a patente K é rotulada como ET se for similar a P e, se P estiver associada a um novo IPC ou CPC) que tenha sido criado até o ano $X+3$. A introdução de novos códigos IPC ou CPC é vista como um indicador do estabelecimento formal de um novo domínio tecnológico, conferindo à tecnologia a persistência necessária para ser considerada emergente. Este método permite a construção de um conjunto de dados rotulados, essencial para o treinamento de modelos de aprendizado de máquina supervisionado subsequentes.

4.3 Aprendizado de Máquina Supervisionado

Nesta fase, algoritmos de aprendizado de máquina serão aplicados para classificar as patentes.

O conjunto de dados de patentes rotuladas, gerado a partir da análise temporal e da extração de tópicos via LDA, é empregado no treinamento de modelos de classificação supervisionada. O objetivo é desenvolver classificadores robustos capazes de prever se uma tecnologia é (ET) ou Não-Emergente (NET), utilizando uma combinação de características textuais, categóricas e numéricas extraídas das patentes.

As patentes são submetidas a um *pipeline* de pré-processamento que transforma e integra os diferentes tipos de atributos tecnológicos:

1. **Atributos Textuais:** O texto consolidado do título e do resumo (`title_abstract`), além dos nomes de inventores (`inventor_names`), é processado utilizando *Term Frequency-Inverse Document Frequency* (TFIDF). Para capturar a relevância das palavras e a relação de sequências, o TFIDF é configurado para incluir *n-grams* de alcance (1, 2), com limitação a 5000 atributos (*features*).
2. **Atributos Numéricos:** Variáveis como ano de publicação, contagem de famílias de patentes e número de reivindicações (`year`, `patent_count`, `family_count`, `claims_count`) são padronizadas via *StandardScaler* para mitigar a influência da escala.

3. **Atributos Categóricos:** Dados de jurisdição, tipo de documento e língua (`jurisdiction`, `kind`, `lang`, etc.) são codificados via *One-Hot Encoding*.

O *dataset* é subsequentemente dividido em conjuntos de treino e teste (*test_size* de 20%) de forma estratificada para manter a proporção da classe alvo em ambos os subconjuntos. O mesmo procedimento foi utilizado tanto para o SVM quanto para o XGBoost.

4.4 Validação e Otimização

Devido à natureza desbalanceada do *dataset*, a avaliação de desempenho é focada na métrica F1-Score (média harmônica entre *precision* e *recall*). Esta escolha garante que a capacidade do modelo de identificar corretamente a classe minoritária (ET) seja adequadamente ponderada.

A otimização de hiperparâmetros (incluindo o custo C e o *kernel* para SVM; `n_estimators`, `max_depth` e `learning_rate` para XGBoost) é realizada utilizando GridSearchCV. O processo de busca visa maximizar o F1-Score (via `f1_macro`), garantindo que o modelo selecionado para a aplicação final apresente a melhor performance generalizável.

5 Resultados Parciais

5.1 Distribuição do Conjunto de Dados e Desafio de Desbalanceamento

A metodologia de rotulagem de patentes, baseada na similaridade semântica e na criação subsequente de novos Códigos de Classificação de Patentes (IPC/CPC) (até $X + 3$), resultou na construção de um *dataset* supervisionado com um notável desbalanceamento de classes.

A proporção observada no conjunto de treinamento (80% dos dados totais) demonstrou que a classe majoritária (Não-Emergente, ou *False*) é significativamente mais frequente que a classe minoritária (Emergente, ou *True*). Especificamente, a proporção calculada (`scale_pos_weight`) foi de aproximadamente 38.13 (4919 patentes Não-Emergentes para 129 Emergentes no conjunto de teste, com proporção similar no treino), confirmando a necessidade de técnicas de mitigação, como o uso do `class_weight='balanced'` no SVM e do `scale_pos_weight` no XGBoost.

5.2 Avaliação Comparativa dos Classificadores

Os resultados de desempenho no conjunto de teste (20% dos dados) para os modelos *SVM* e *XGBoost*, configurados com o balanceamento de classes, são apresentados na Tabela 5.2.

Modelo	Acurácia	Precision (ET)	Recall (ET)	F1-Score (Macro)
SVM	0.9166	0.09	0.24	0.54
XGBoost	0.9275	0.16	0.42	0.59

Tabela 1: Resultados de Classificação para os Modelos Balanceados. A precisão e o recall referem-se à classe minoritária (Emergente - ET/True)..

Apesar de ambos os modelos apresentarem alta acurácia (acima de 91%), este valor é enganoso devido à preponderância da classe Não-Emergente. Portanto, a análise de mérito deve se concentrar nas métricas de desempenho da classe minoritária e no *F1-Score* Macro.

O desempenho da Classe Emergente (ET) demonstrou que o *XGBoost* superou o *SVM* em ambas as métricas críticas para a classe minoritária. O *Recall* do *XGBoost* foi significativamente superior, atingindo **0.42** contra 0.24 do *SVM*, indicando maior eficácia do *XGBoost* em identificar corretamente as patentes genuinamente emergentes (*True Positives*). A Precisão do *XGBoost* também se mostrou mais alta (0.16 vs 0.09), o que contribui para a redução da taxa de Falsos Positivos. Por fim, o *F1-Score* Macro, métrica que pondera igualmente o desempenho em ambas as classes, confirmou a superioridade geral do *XGBoost* (**0.59**) em comparação com o *SVM* (0.54).

A partir desta avaliação, o modelo *XGBoost* demonstrou maior robustez e eficácia na tarefa crítica de identificar tecnologias emergentes em um cenário altamente desbalanceado, sendo o candidato preferencial para a etapa de predição final em dados de patentes mais recentes.

6 Discussão e Conclusão

Para aprimorar a precisão na identificação de tecnologias emergentes (ETs) e superar o desafio de detectar eventos raros, a metodologia será substancialmente refinada nas etapas de rotulagem e classificação. O processo de rotulagem será aprimorado ao focar-se na semelhança conceitual entre tópicos ou clusters inteiros de patentes, em vez de analisar patentes individualmente. Essa abordagem em nível de cluster utiliza vetores de características agregados (calculados pela média das características das patentes no grupo) para capturar a coerência e a persistência da emergência tecnológica de forma mais robusta e representativa.

A etapa de classificação será fortalecida pela expansão do conjunto de features de entrada, uma prática crucial para detectar ETs em estágios iniciais. Serão adicionados novos indicadores bibliométricos e de escopo tecnológico, como o número de Códigos de Classificação de Patentes (IPC/CPC). Este indicador serve como proxy para a abrangência e generalidade da invenção, sendo um sinal precoce relevante. Outras características multidimensionais, como o desempenho histórico do inventor e do cessionário (IAHP), também serão integradas, pois sua inclusão demonstrou aumentar o desempenho na previsão de tecnologias promissoras.

Por fim, para enfrentar o problema do desequilíbrio de dados (dado que as ETs são eventos raros), serão testadas técnicas avançadas de amostragem. Isso incluirá a criação de dados sintéticos utilizando Generative Adversarial Networks (GAN), uma metodologia de data augmentation eficaz para treinar classificadores de deep learning com amostras limitadas. Em complemento, serão testadas técnicas de under sampling e over sampling (como ROSE ou SMOTE) para equilibrar a distribuição de classes no conjunto de treinamento e garantir a robustez do classificador.

Referências

- Beatto, V. M., & Back, R. B. (2022). Levantamento de patentes tecnológicas que contribuem para a acessibilidade na construção civil. *Revista de Arquitetura IMED*, 11(1), 151–170. <https://doi.org/10.18256/2318-1109.2022.v11i1.4719> [GS Search].
- Choi, Y., Park, S., & Lee, S. (2021). Identifying emerging technologies to envision a future innovation ecosystem: A machine learning approach to patent data. *Scientometrics*, 126(7), 5431–5476. <https://doi.org/10.1007/s11192-021-04001-1> [GS Search].
- Colares, A. C. V., Gouvêa, D. A. P., & Costa, J. S. (2021). Impactos da pandemia do covid-19 no setor de construção civil. *Percorso Acadêmico*, 11(21), 188–208.
- Erdogan, Z., Altuntas, S., & Dereli, T. (2022). Predicting patent quality based on machine learning approach. *IEEE Transactions on Engineering Management*, 71, 3144–3157. <https://doi.org/10.1109/TEM.2022.9904033> [GS Search].
- Kreuchau, F., & Korzinov, V. (2017). A patent search strategy based on machine learning for the emerging field of service robotics. *Scientometrics*, 111(2), 743–772. <https://doi.org/10.1007/s11192-017-2268-3> [GS Search].
- Kwon, U., & Geum, Y. (2020). Identification of promising inventions considering the quality of knowledge accumulation: A machine learning approach. *Scientometrics*, 125(3), 1877–1897. <https://doi.org/10.1007/s11192-020-03710-3> [GS Search].
- Kyebambe, M. N., Cheng, G., Huang, Y., He, C., & Zhang, Z. (2017). Forecasting emerging technologies: A supervised learning approach through patent analysis. *Technological Forecasting and Social Change*, 125, 236–244.
- Lee, C., Kwon, O., Kim, M., & Kwon, D. (2018). Early identification of emerging technologies: A machine learning approach using multiple patent indicators. *Technological Forecasting and Social Change*, 127, 291–303. <https://doi.org/10.1016/j.techfore.2017.11.002> [GS Search].
- Mohammadi, N., Maghsoudi, M., & Soghi, M. (2024). Innovation ecosystems in retail: Uncovering technological trends and collaboration networks through patent mining. *IEEE Access*. <https://doi.org/10.1109/ACCESS.2024.10792909> [GS Search].
- Munaro, M. R., & Tavares, S. F. (2022). A economia circular na construção civil: principais barreiras e oportunidades para a transição do setor. *Revista Tecnologia e Sociedade*, 18(53), 54–71.
- Ranaei, S., & Suominen, A. (2017). Using machine learning approaches to identify emergence: Case of vehicle related patent data. *2017 Portland International Conference on Management of Engineering and Technology (PICMET)*, 1–8. <https://doi.org/10.23919/PICMET.2017.8125290> [GS Search].
- Zhou, Y., Dong, F., Liu, Y., & Ran, L. (2021). A deep learning framework to early identify emerging technologies in large-scale outlier patents: An empirical study of CNC machine tool. *Scientometrics*, 126(2), 969–994. <https://doi.org/10.1007/s11192-020-03797-8> [GS Search].