
Submission: dd/Mmm/yyyy;	1 st round notif.: dd/Mmm/yyyy;	New version: dd/Mmm/yyyy;	2 nd round notif.: dd/Mmm/yyyy;
Camera ready: dd/Mmm/yyyy;	Edition review: dd/Mmm/yyyy;	Available online: dd/Mmm/yyyy;	Published: dd/Mmm/yyyy;

Identificação de tecnologias emergentes a partir de dados de patentes usando ML na área da construção civil

Dimitri Prado
Universidade de São Paulo
dimitriprado@usp.br

Luis Henrique Moraes
Universidade de São Paulo
luishmoraes@usp.br

Pedro Oliveira Fernandes
Universidade de São Paulo
pedro.oliveiraf@usp.br

Rodrigo Lyusei Suguimoto
Universidade de São Paulo
rodrigo.lyusei@usp.br

Resumo

A identificação precoce de tecnologias emergentes constitui um desafio para setores consolidados como o da construção civil, onde métodos tradicionais de análise podem ser insuficientes. Este estudo propõe uma metodologia para a identificação de tecnologias emergentes no setor da construção civil brasileira, combinando modelagem de tópicos (Latent Dirichlet Allocation - LDA) e aprendizado de máquina (ML) supervisionado. Para isso, é realizada a coleta e o pré-processamento de patentes brasileiras da base Lens.org. O modelo LDA é aplicado para identificar temas latentes e extrair vetores de características semânticas. A "emergência" de cada patente é rotulada por meio de uma abordagem objetiva inovadora, que combina a similaridade semântica com patentes futuras e a criação de novos códigos de classificação (IPC/CPC), indicando a persistência e formalização da tecnologia. Algoritmos de classificação (SVM e XGBoost) são então treinados para prever tecnologias promissoras. Os resultados demonstram que o XGBoost supera o SVM na identificação de casos raros e que a definição correta da janela temporal é crucial para a performance preditiva.

Palavras-chave: Construção Civil; Patentes; Tecnologias Emergentes; Machine Learning

1 Introdução

O setor da construção civil tem importância tanto no aspecto social quanto no econômico, sendo uma das áreas que mais contribui para a geração de empregos e o aquecimento da economia. Sua robustez foi demonstrada durante a pandemia de COVID-19, quando foi considerado um serviço essencial e conseguiu manter a estabilidade, com a maioria das empresas atingindo ou superando os resultados esperados (Colares et al., 2021).

Porém, a área da construção civil enfrenta um grave problema de sustentabilidade, sendo o maior consumidor mundial de matérias-primas e exercendo enorme pressão sobre os recursos naturais. De acordo com Munaro e Tavares (2022), o setor é responsável por uma parcela significativa dos impactos ambientais globais, gerando até 35% dos resíduos em aterros, respondendo por 36% do uso final de energia e 39% das emissões globais de dióxido de carbono. Diante disso, observamos a necessidade de mudança nos padrões de produção e consumo, realizando a transição para uma economia circular.

O problema surge quando essa transição é dificultada pelo fato de o setor ser historicamente conservador e tecnologicamente atrasado. A própria complexidade da sua cadeia de valor e a falta de mão de obra qualificada para novas ferramentas representam barreiras. Eventos recentes, como a própria pandemia, acabaram estimulando a necessidade de uma transformação digital, impulsionando o interesse em tecnologias como inteligência artificial, Big Data, impressão 3D e o uso de drones, que já demonstram seu valor em áreas correlatas (Colares et al., 2021).

Assim, vemos que a inovação tecnológica é fundamental para a competitividade e o desenvolvimento sustentável. Para indústrias consolidadas, como a da construção civil, a capacidade de identificar tecnologias emergentes de forma antecipada é um diferencial estratégico crucial, permitindo que as empresas se adaptem, lancem novos produtos e otimizem processos existentes (Choi et al., 2021). A identificação de tendências promissoras possibilita o direcionamento de investimentos em pesquisa e desenvolvimento para áreas com maior potencial de retorno, garantindo uma vantagem competitiva (Lee et al., 2018).

Diante desse desafio, a literatura recente tem explorado modelos para superar os métodos tradicionais. Uma vertente promissora é o uso de modelos de tópicos, como o Latent Dirichlet Allocation (LDA), que permite descobrir estruturas temáticas latentes em grandes volumes de texto, indo além da simples contagem de palavras-chave e identificando os conceitos tecnológicos subjacentes (Ranaei & Suominen, 2017). Outros estudos argumentam que a identificação da emergência, ou seja, de patentes com pouca similaridade com o conhecimento existente, é um indicador mais preciso de tecnologias disruptivas. Essa visão é reforçada pela necessidade de avaliar o potencial de uma tecnologia em diversos aspectos, combinando tanto seu impacto tecnológico, frequentemente medido por citações futuras, quanto seu impacto social (Zhou et al., 2021).

Avançando nessa linha, pesquisadores têm proposto a combinação de múltiplos indicadores de patentes para criar uma avaliação mais robusta da qualidade ou do potencial de uma invenção (Erdogan et al., 2022; Lee et al., 2018). A lógica é que características intrínsecas da patente, disponíveis no momento de sua publicação, como o número de reivindicações, o número de inventores e as referências a artigos, podem servir como sinais precoces de seu futuro impacto (Lee et al., 2018). Essa abordagem busca construir uma métrica de "qualidade" ou "potencial" que seja mais preditiva e menos dependente do tempo do que as citações isoladas (Erdogan et al., 2022).

Este estudo se insere nesse contexto e propõe um framework metodológico para a identificação de tecnologias emergentes na construção civil brasileira, que integra a modelagem de tópicos com uma métrica híbrida de potencial de emergência. O objetivo é desenvolver um método que não apenas identifique os temas tecnológicos em ascensão, mas que também os classifique com base em um indicador composto.

2 Trabalhos Correlatos

A análise de patentes tornou-se uma fonte importante para rastrear tendências tecnológicas e identificar inovações emergentes. Métodos tradicionais são úteis, mas apresentam limitações, como subjetividade, dificuldade em processar grandes volumes de dados e ambiguidade de palavras-chave (Beatto & Back, 2022; Choi et al., 2021; Ranaei & Suominen, 2017). Nesse cenário, a análise de dados e o aprendizado de máquina vêm transformando a prospecção tecnológica, permitindo uma transição de análises retrospectivas para abordagens preditivas (Erdogan et al., 2022; Kreuchauff & Korzinov, 2017; Lee et al., 2018; Zhou et al., 2021).

Diversos estudos recentes têm aplicado classificadores supervisionados para essa tarefa. Choi et al. (2021), por exemplo, propõem uma abordagem híbrida que combina percepções de especialistas com dados de patentes, utilizando aprendizado ativo e classificadores como Random Forest (RF), Support Vector Machine (SVM) e Extreme Gradient Boosting (XGBoost) no setor de baterias para veículos elétricos. Na mesma linha, Lee et al. (2018) e Kwon e Geum (2020) também demonstram a eficácia do RF e do SVM para detectar invenções promissoras. Embora nosso estudo também aplique SVM e XGBoost, ele se diferencia fundamentalmente em dois aspectos: primeiro, focamos em um domínio distinto e menos explorado por essas técnicas, a construção civil; segundo, propomos uma metodologia de rotulagem objetiva que não depende da intervenção de especialistas, baseando-se em indicadores da própria base de patentes.

No que tange à rotulagem e à extração de características, outras abordagens são relevantes. Ranaei e Suominen (2017) exploraram o uso de modelos não supervisionados, como o Latent Dirichlet Allocation (LDA), para detectar padrões de emergência a partir do texto de patentes de veículos, analisando o crescimento dos tópicos ao longo do tempo. Já Kyebambe et al. (2017) aborda a escassez de dados rotulados, propondo um método que utiliza a criação de novas classes no sistema de classificação de patentes (USPC) como um indicador objetivo de emergência tecnológica. Nosso trabalho se baseia e combina essas duas vertentes de forma inovadora: diferentemente de Ranaei e Suominen (2017), não usamos o LDA apenas de forma exploratória, mas sim como uma ferramenta de extração de características para alimentar nossos modelos supervisionados. E, de forma inspirada em Kyebambe et al. (2017), utilizamos a criação de novos códigos (IPC/CPC) como critério de rotulagem, mas refinamos ao combiná-lo com uma análise de similaridade semântica para garantir a persistência da tecnologia.

Embora trabalhos como os de Mohammadi et al. (Mohammadi et al., 2024) exploraram redes de colaboração para identificar tendências, identificamos uma lacuna clara na literatura: a aplicação de uma metodologia híbrida que integre modelagem de tópicos e classificação supervisionada (XGBoost, SVM) para a identificação de tecnologias emergentes, especificamente no setor da construção civil e com foco no ecossistema de inovação brasileiro. A maioria dos estudos foca em setores de alta tecnologia, como TICs ou baterias, e em bases de patentes internacionais

(USPTO, EPO). Nossa proposta visa preencher essa lacuna, oferecendo um método adaptado às particularidades e ao volume de dados do contexto nacional.

3 Fundamentos Teóricos

3.1 Mineração de texto

A Mineração de Texto pode ser definida como o processo computacional de descobrir conhecimento e extrair informações de alta qualidade a partir de grandes volumes de dados textuais. O desafio central dessa área é que os textos, como os encontrados em documentos de patentes, são dados não estruturados, ou seja, não estão organizados em um formato de banco de dados tradicional, o que impede sua análise direta por máquinas. O objetivo da mineração de texto é, portanto, transformar esses textos livres em dados estruturados e interpretáveis.

O processo de mineração é tipicamente dividido em etapas sequenciais: o pré-processamento, que visa limpar e padronizar os dados brutos por meio de tarefas como a tokenização, quebrando o texto em unidades menores; a remoção de stopwords, palavras muito frequentes e com baixo valor semântico; e a normalização, que consiste na redução das palavras às suas formas radicais. Em seguida, os textos limpos são convertidos em uma representação numérica. Modelos clássicos, como o Bag-of-Words (BoW), realizam essa tarefa contando a frequência de cada palavra.

Com os textos em formato vetorial, aplicam-se técnicas de aprendizado de máquina (machine learning) ou estatísticas para, de fato, extrair os padrões. Isso pode envolver a redução de dimensionalidade, essencial para lidar com a alta variabilidade dos dados textuais, ou a aplicação de algoritmos de clusterização para agrupar documentos por similaridade. No contexto deste trabalho, a mineração de texto é a ferramenta-chave para analisar o vasto repositório de patentes, permitindo mapear tendências e identificar inovações emergentes, como demonstrado em Ranaei e Suominen, 2017.

3.1.1 *Latent Dirichlet Allocation (LDA)*

O LDA é um modelo de tópicos (topic modeling) probabilístico e generativo, amplamente utilizado para descobrir os temas latentes (ocultos) em uma coleção de documentos (ou corpus). Ele apresenta duas premissas fundamentais:

1. Cada documento é visto como uma mistura de múltiplos tópicos, em diferentes proporções (por exemplo, uma patente de construção pode ser 80% sobre "Novos Compósitos Cimentícios" e 20% sobre "Eficiência Energética").
2. Cada tópico é definido como uma distribuição de probabilidades sobre um conjunto de palavras do vocabulário (o tópico "Novos Compósitos Cimentícios" teria alta probabilidade de gerar palavras como "cimento", "agregado", "resíduo", "resistência" e "fibra").

O LDA não exige que os tópicos sejam definidos previamente pelo pesquisador. O modelo analisa a coocorrência das palavras ao longo de todos os documentos para inferir, estatisticamente,

quais grupos de palavras tendem a aparecer juntos, formando assim os tópicos. O nome *Dirichlet* deriva do uso de distribuições de Dirichlet em sua formulação matemática, que são adequadas para modelar as proporções (tanto a distribuição de tópicos por documento quanto a distribuição de palavras por tópico). O LDA permite organizar e resumir grandes volumes de dados textuais em temas coerentes.

3.2 Modelos de Predição Supervisionados

Modelos preditivos são algoritmos de aprendizado de máquina (machine learning) treinados para identificar padrões em dados históricos com o objetivo de prever resultados futuros. O emprego desses modelos é vasto, permitindo, por exemplo, antecipar tendências ou classificar novos dados com base em exemplos passados. O processo de "treinamento" consiste em alimentar o algoritmo com um conjunto de dados para que ele aprenda as relações matemáticas entre as variáveis de entrada (as features) e uma variável de saída.

Neste trabalho, o foco recai sobre o aprendizado supervisionado. Este paradigma de treinamento exige, como pré-requisito, um conjunto de dados previamente rotulado. Isso significa que, para cada amostra (ou tupla) dos dados de treino, o valor da variável de interesse (o rótulo) já é conhecido. O algoritmo, então, aprende a mapear as entradas para a saída correta, generalizando esse aprendizado para prever os rótulos de dados futuros, que não foram usados para o treinamento. Um exemplo de aplicação dessa técnica para análise de patentes pode ser encontrado em Kyebambe et al., 2017.

3.2.1 *Extreme Gradient Boosting (XGBoost)*

O Extreme Gradient Boosting (XGBoost) é um algoritmo de ensemble (conjunto) supervisionado, baseado na técnica de boosting (reforço). Modelos de boosting constroem um aprendiz forte de forma iterativa, através da combinação sequencial de múltiplos aprendizes fracos, que são, tipicamente, árvores de decisão.

Diferente de outros métodos que combinam árvores, como o Random Forest, o XGBoost funciona de maneira aditiva: ele treina uma primeira árvore, avalia seus erros de predição, e então treina a próxima árvore focando especificamente em corrigir as falhas da anterior. O termo Gradient em seu nome deriva do uso do algoritmo de otimização de gradiente descendente (gradient descent), que é utilizado para minimizar a função de perda (o erro de predição) a cada nova árvore adicionada ao modelo. Essa abordagem o torna uma das ferramentas mais eficientes e precisas para problemas de classificação e regressão.

3.2.2 *Support Vector Machine (SVM)*

O Support Vector Machine (SVM), ou Máquina de Vetores de Suporte, é outro robusto algoritmo de aprendizado supervisionado, classicamente utilizado para tarefas de classificação binária. A intuição central do SVM é encontrar um hiperplano (uma linha, em duas dimensões, ou um plano, em três) que melhor separe os pontos de dados pertencentes a classes opostas em um espaço vetorial.

O melhor hiperplano é definido como aquele que maximiza a margem, ou seja, a distância

entre ele e os pontos de dados mais próximos de cada classe. Esses pontos mais próximos, que suportam o hiperplano e definem a margem, são chamados de vetores de suporte. Para lidar com conjuntos de dados que não são linearmente separáveis no espaço original, o SVM emprega o chamado kernel trick (truque do kernel), que projeta os dados em um espaço de dimensão superior onde uma separação linear se torna possível.

3.2.3 Grid Search

A performance de algoritmos como o XGBoost ou o SVM depende de hiperparâmetros: configurações pré-treinamento (como o número de árvores no XGBoost ou o tipo de kernel no SVM) que definem a arquitetura e o comportamento do modelo. A escolha inadequada desses valores pode levar a um baixo desempenho.

Para encontrar a combinação ideal de forma sistemática, utiliza-se a técnica de Grid Search (Busca em Grade), na qual o pesquisador define um conjunto de valores discretos que deseja testar. O Grid Search então executa um processo exaustivo, treinando e avaliando um modelo para cada combinação possível desses valores. Ao final, a combinação de hiperparâmetros que gerar o modelo com os resultados mais precisos, de acordo com uma métrica de avaliação pré-definida, é a escolhida.

3.2.4 Matriz de Confusão

A matriz de confusão é uma ferramenta para avaliar o desempenho de um modelo decisor, ao comparar o valor predito pelo modelo com o valor real de uma tupla. Em um cenário de classificação binária (onde a saída é "Positivo" ou "Negativo"), a matriz é estruturada em quatro quadrantes principais:

- Verdadeiros Positivos (VP): O modelo previu corretamente a classe Positivo.
- Verdadeiros Negativos (VN): O modelo previu corretamente a classe Negativo.
- Falsos Positivos (FP): O modelo previu Positivo, mas a classe real era Negativo.
- Falsos Negativos (FN): O modelo previu Negativo, mas a classe real era Positivo.

A partir desses valores, podemos calcular diferentes métricas que fornecem uma visão mais aprofundada sobre a performance do modelo.

$$1. \text{Acurácia (Accuracy)} = \frac{VP+VN}{VP+VN+FP+FN}$$

$$2. \text{Sensibilidade (Recall)} = \frac{VP}{VP+FN}$$

$$3. \text{Precisão (Precision)} = \frac{VP}{VP+FP}$$

$$4. \text{Especificidade (Specifity)} = \frac{VN}{VN+FP}$$

$$5. \text{F-Score} = \frac{2*Recall*Precision}{Recall+Precision}$$

4 Metodologia

A metodologia proposta está estruturada para identificar sistematicamente e analisar tecnologias emergentes no setor da construção civil, utilizando dados de patentes brasileiras e técnicas de aprendizado de máquina. Inspirado na abordagem encontrada em Choi et al., 2021, o processo é dividido em três fases macro: (1) Coleta e Pré-Processamento dos Dados, (2) Modelagem e Classificação de Patentes, e (3) Mapeamento do Ecossistema de Inovação.

4.1 Coleta e Pré-Processamento de Dados

Os dados brutos de patentes foram coletados da base de dados Lens.org, uma plataforma que oferece acesso a uma coleção de patentes globais e artigos acadêmicos. A busca foi realizada por meio de uma query booleana, combinando palavras-chave e termos técnicos relevantes para o domínio da construção civil.

A busca foi direcionada aos campos de título e resumo para garantir a relevância dos documentos. Foi aplicado um filtro geográfico para restringir os resultados a patentes depositadas junto a órgãos brasileiros, como o Instituto Nacional da Propriedade Industrial (INPI). Os dados extraídos (autor, ano de depósito, título, resumo, classificações, etc.) foram exportados em formato de planilha para processamento subsequente. Foram coletadas 50000 patentes, seguindo o limite de nossa base.

Os dados não são diretamente utilizáveis pelos algoritmos. Portanto, uma fase de engenharia de atributos será conduzida. A partir de colunas como "nº de inventores", "nº de reivindicações" e do conteúdo textual de "título" e "resumo", serão extraídas e calculadas variáveis preditoras. Inspirado no artigo de referência, estas variáveis podem ser agrupadas em categorias como: características da invenção; características do depositante; características de palavras-chave.

A variável-alvo, que define uma tecnologia como "emergente" ou "promissora", será operacionalizada considerando a data de criação do IPC daquela patente e as palavras-chave que a definem.

4.2 Rotulação de patentes

A determinação de tecnologias promissoras ou emergentes (ETs) é abordada neste estudo como um problema de classificação supervisionada, fundamental para o planejamento tecnológico estratégico. O processo inicia-se com a representação das patentes, na qual o conteúdo textual é utilizado como proxy das características tecnológicas (Ranaei & Suominen, 2017).

Especificamente, empregamos o algoritmo Latent Dirichlet Allocation (LDA) para a análise de palavras, seguindo métodos de avaliação tecnológica que utilizam mineração de texto. O LDA, sendo um modelo preditivo, é utilizado para redução de dimensionalidade e extração de tópicos latentes, o que supera as limitações dos modelos tradicionais baseados apenas na contagem de palavras, tratando a ambiguidade na linguagem natural.

A base de dados de patentes foi inicialmente segmentada de acordo com o ano de publicação X para capturar a evolução temporal. Em seguida, o algoritmo LDA foi aplicado iterativamente para cada ano. O número de tópicos K foi variado nos testes.

A rotulagem das patentes foi realizada utilizando uma regra objetiva, baseada na premissa de que as tecnologias emergentes devem demonstrar coerência e persistência ao longo do tempo. Este procedimento foi inspirado na metodologia de Kyebambe et al. (2017), que emprega a criação de novas classes de classificação de patentes como um indicador de emergência.

Para rotular uma patente K do ano X são necessárias duas condições. Primeiro, é calculada a similaridade semântica entre a patente K e um conjunto de patentes P , publicadas nos i anos posteriores. Nesta etapa, a análise se fundamenta na criação de vetores de características ponderados para cada patente, derivados dos resultados do LDA, considerando as N palavras mais importantes de cada tópico e suas respectivas probabilidades, informações estas que são extraídas dos tópicos associados a cada documento.

A quantificação da similaridade entre os vetores da patente K e de uma patente futura P é realizada através do coeficiente de Tanimoto (Jaccard Ponderado) ou da Similaridade de Cossenos. Essas métricas são complementares: enquanto o coeficiente de Tanimoto avalia a sobreposição da magnitude dos pesos probabilísticos compartilhados, a Similaridade de Cossenos mede o alinhamento angular dos vetores no espaço semântico, focando na orientação temática.

Depois, a patente K é rotulada como ET se for similar a uma das patentes P e, se P estiver associada a um novo IPC ou CPC que tenha sido criado até o ano $X+3$. A introdução de novos códigos IPC ou CPC é vista como um indicador do estabelecimento formal de um novo domínio tecnológico, conferindo à tecnologia a persistência necessária para ser considerada emergente.

4.3 Aprendizado de Máquina Supervisionado

Nesta fase, algoritmos de aprendizado de máquina serão aplicados para classificar as patentes.

O conjunto de dados de patentes rotuladas, gerado a partir da análise temporal e da extração de tópicos via *LDA*, é empregado no treinamento de modelos de classificação supervisionada. O objetivo é desenvolver classificadores robustos capazes de prever se uma tecnologia é (ET) ou Não-Emergente (NET), utilizando uma combinação de características textuais, categóricas e numéricas extraídas das patentes.

A construção do conjunto de dados final para a modelagem inicia-se pela consolidação das fontes de dados. Sendo assim são incluídos atributos pré-calculados, tais como *family_count*, *claims_count* e o indicador *booleano new_ipcr*, o mesmo utilizado para a rotulagem dos dados. Realiza-se também a engenharia de novos atributos a partir de metadados estruturados, para extrair informações quantitativas e categóricas, como o *num_cpc_codes* (a contagem total de classificações CPC), *num_applicants* (o número de requerentes listados), *num_priority_claims* (a contagem total de reivindicações de prioridade), *inventors_count* (a quantidade de inventores envolvidos na criação da patente) e *has_foreign_priority* (um atributo *booleano* que sinaliza a existência de prioridade estrangeira, verificando se alguma jurisdição é diferente de 'BR').

Por último, é aplicada uma filtragem temporal. Todos os registros com ano de publicação igual a 1999 ou 2024 são excluídos do conjunto de dados inicialmente para garantir a integridade, uma vez que nesses anos muitos campos estavam ausentes. Adicionalmente, são removidos também os i últimos anos da série (2022-2024) porque neles não é possível confirmar a "emergência" futura (falta de dados $X + 3$), conforme detalhado na seção de Resultados.

Depois de construir o conjunto de dados para o treinamento, as patentes são submetidas a um *pipeline* de pré-processamento que transforma e integra os diferentes tipos de atributos tecnológicos:

1. **Atributos Textuais:** O texto consolidado do título e do resumo (*title_abstract*), além dos nomes de inventores (*inventor_names*), é processado utilizando *Term Frequency-Inverse Document Frequency (TFIDF)*. Para capturar a relevância das palavras e a relação de sequências, o *TFIDF* é configurado para incluir *n-grams* de alcance (1,2), com limitação a 5000 atributos (*features*).
2. **Atributos Numéricos:** Variáveis pré-existentes como ano de publicação, contagem de famílias e número de reivindicações (*year*, *patent_count*, *family_count*, *claims_count*) são combinadas com atributos derivados dos metadados. Estes atributos incluem a contagem de códigos IPC (*num_ipc_codes*), o número de requerentes (*num_applicants*) e o número de reivindicações de prioridade (*num_priority_claims*). O conjunto completo destes atributos é padronizado via *StandardScaler* para mitigar a influência da escala.
3. **Atributos Categóricos:** Variáveis nominais como o tipo de documento (*kind*), tipo de publicação (*publication_type*), estado da patente (*patent_status*) e indicadores booleanos (*new_ipcr*, *picked*) são processados. Adicionalmente, um atributo booleano (*has_foreign_priority*) é extraído, identificando a presença de qualquer reivindicação de prioridade com jurisdição fora do Brasil ('BR'). Todos estes atributos são codificados via *One-Hot Encoding*.

O *dataset* é subsequentemente dividido em conjuntos de treino e teste (*test_size* de 20%) de forma estratificada para manter a proporção da classe alvo em ambos os subconjuntos.

4.4 Validação e Otimização

Devido à natureza desbalanceada do *dataset*, a avaliação de desempenho é realizada utilizando métricas para identificação da classe minoritária, focando na *precisão* e *F1-Score*.

A *precisão* é priorizada por estar diretamente relacionada ao objetivo de minimizar falsos positivos. Pois a penalidade associada a um falso positivo é considerada mais severa do que a de um falso negativo. Onde o resultado desejado se concentra em ter o maior número de predições positivas corretas entre todas as predições positivas feitas.

O *recall*, embora importante, não é o foco principal, pois se concentra na cobertura de todas as instâncias positivas, o que implicaria uma tolerância maior a falsos positivos para maximizar o número de verdadeiros positivos.

O *F₁-Score* (média harmônica entre *precision* e *recall*) é utilizado como métrica secundária e de suporte, pois oferece um equilíbrio entre as duas, garantindo que o modelo não maximize a *precisão* às custas de um *recall* excessivamente baixo.

A otimização de hiperparâmetros (incluindo o custo *C* e o *kernel* para *SVM*; *n_estimators*, *max_depth*, *learning_rate*, *gamma* e *reg_alpha* para *XGBoost*) é realizada utilizando a técnica *GridSearchCV*. O processo de busca visa maximizar a *precisão* ou o *F1-Score* (*via f1*), garantindo que o modelo selecionado para a aplicação final apresente a melhor performance para a métrica escolhida.

5 Resultados

5.1 Análise Qualitativa dos Tópicos

A inspeção visual dos tópicos gerados para os anos de 2002, 2003 e 2004 (Figuras 1, 2 e 3) confirma a capacidade do LDA de agrupar as patentes em temas tecnologicamente coerentes.




Figura 1: Distribuição de palavras por tópico no ano de 2002..




Figura 2: Distribuição de palavras por tópico no ano de 2003..

Em 2002 (Figura 1), a distinção entre os domínios é nítida. O Tópico 1 concentra termos da área hidrossanitária ("água", "vaso", "válvula"), enquanto os Tópicos 0 e 2 focam em elementos estruturais e de vedação ("parede", "pisso", "telha", "vidro"). O Tópico 3, por sua vez, agrupa mecanismos de acesso e segurança ("porta", "fechadura").



Figura 3: Distribuição de palavras por tópico no ano de 2004..

Nos anos seguintes, a estrutura temática apresenta estabilidade, com evoluções pontuais. Em 2003, o termo "concreto" ganha relevância no Tópico 3, sugerindo foco em métodos construtivos. Já em 2004, o termo "energia" surge no Tópico 3, indicando possíveis inovações em eficiência ou sistemas de aquecimento.

Apesar da coerência temática, observa-se a predominância de termos genéricos em todos os anos, como "dispositivo", "elemento" e "conjunto". Isso reforça a tese deste trabalho: como o vocabulário macro da construção civil muda lentamente, a identificação de tecnologias verdadeiramente emergentes não pode depender apenas da frequência de palavras, exigindo a validação cruzada com a criação de novos códigos de classificação (IPC/CPC), conforme proposto na metodologia.

5.2 Rotulação de patentes por ano

Foram feitos diversos testes para a rotulação de patentes emergentes, considerando diferentes parâmetros na nossa metodologia. Nessa seção, serão demonstrados alguns desses experimentos.

Observando as Figuras 4, 5 e 6, percebemos que, com o aumento da quantidade de tópicos, as curvas marcando a quantidade de patentes emergentes por tópico fica mais suave.

Além disso, uma maior quantidade de tópicos na análise trouxe uma menor quantidade de patentes rotuladas como ET. Nos 3 últimos anos, 2022, 2023 e 2024 nenhuma patente foi rotulada como emergente, devido a configuração para comparar as patentes com 3 anos a frente. Também é interessante ressaltar que a curva das figuras é similar.

Conforme observado na análise qualitativa dos tópicos (Seção 5.1) LDA opera em nível macro. Ele identifica padrões latentes amplos no vocabulário, não variações finas dentro de um mesmo domínio tecnológico. Isso significa que pequenas evoluções semânticas, típicas de microinovações, não geram deslocamentos suficientes na distribuição de tópicos para alterar a similaridade temporal.




Figura 4: Total de patentes emergentes por ano. Configuração: 5 tópicos, 5 palavras para análise de similaridade (cosseno) e 80% de limite.




Figura 5: Total de patentes emergentes por ano. Configuração: 10 tópicos, 5 palavras para análise de similaridade (cosseno) e 80% de limite.




Figura 6: Total de patentes emergentes por ano. Configuração: 30 tópicos, 5 palavras para análise de similaridade (cosseno) e 80% de limite.

Como os tópicos permanecem estáveis ao longo dos anos, as curvas resultantes mostram praticamente a mesma estrutura, independentemente dos valores de K ou do número de palavras usadas. O modelo só reage quando há mudanças significativas no conteúdo técnico das patentes,

produzindo padrões que refletem transições tecnológicas amplas.




Figura 7: Total de patentes emergentes por ano. Configuração: 10 tópicos, 5 palavras para análise de similaridade (cosseno) e 70% de limite.

Feita uma diminuição no limite de similaridade entre as patentes para definir a emergência (Figura 5.2), há um grande aumento na quantidade de patentes marcadas como ET porém observa-se que a curva continua a mesma, considerando a mesma quantidade de tópicos.




Figura 8: Total de patentes emergentes por ano. Configuração: 10 tópicos, 8 palavras para análise de similaridade (cosseno) e 80% de limite.

Por fim, feito um aumento no número de palavras usados para a análise de similaridade (Figura 5.2), observa-se uma grande diminuição na quantidade de patentes emergentes encontrada, porém a curva continua semelhante a principal de análise.

5.3 Exemplo de Uma Patente Rotulada Como Emergente

Um exemplo de tecnologia rotulada como emergente (ET) por nossa metodologia é a patente BR0113509A - "Acabamento extraível resistente ao risco", depositada em 2001 e publicada em 2005, disponível na plataforma lens pelo id [031-219-148-610-739](#).

O resumo da patente descreve "um acabamento de piso curável por radiação aplicado no local de uso" contendo partículas inorgânicas, que confere resistência a riscos, mas que ainda pode

ser removido por extração. O foco central desta invenção é melhorar o processo de acabamento pós-instalação, oferecendo uma solução superior aos pisos pré-acabados de fábrica. Ela soluciona problemas como as pequenas diferenças de altura entre painéis de assoalho adjacentes e o selamento ineficaz de fissuras, que não podem ser corrigidos após a instalação sem danificar o acabamento original de fábrica.

A patente BR 0113509 A serve como um exemplo sólido de *ET* por satisfazer os dois critérios cruciais da nossa rotulagem híbrida:

1. **Similaridade Semântica Persistente:** O modelo LDA teria mapeado esta invenção para tópicos de alto nível, como "Compostos Químicos/Polímeros para Construção" e "Revestimentos Duráveis". O rótulo *ET* indica que o vetor semântico gerado pelo LDA para esta patente demonstrou alta similaridade (acima do limiar de 80% ou 70%) com patentes publicadas nos anos subsequentes ($X + i$). Essa persistência temática valida que o conceito introduzido não foi uma ideia isolada, mas sim o ponto de partida de uma tendência tecnológica duradoura.
2. **Formalização por Novo Código IPC/CPC:** O fator decisivo para o rótulo *ET* é que as patentes futuras similares foram associadas à criação de um novo código de classificação IPC ou CPC na área de revestimentos para construção civil dentro do horizonte temporal analisado ($X + 3$). A introdução de um novo código de classificação pelo órgão regulador (INPI/EPO) funciona como um indicador objetivo de que o domínio tecnológico se estabeleceu formalmente, confirmando a emergência e a formalização da área de polímeros de alta resistência aplicados *in loco* como um novo campo de estudo.

5.4 Distribuição do Conjunto de Dados e Desafio de Desbalanceamento

A metodologia de rotulagem de patentes, baseada na similaridade semântica e na criação subsequente de novos Códigos de Classificação de Patentes (*IPC/CPC*) (até $X + 3$), resultou na construção de um *dataset* supervisionado com um notável desbalanceamento de classes.

A proporção observada no conjunto de treinamento (80% dos dados totais) demonstrou que a classe majoritária (Não-Emergente, ou *False*) é significativamente mais frequente que a classe minoritária (Emergente, ou *True*). Especificamente, a proporção calculada (*scale_pos_weight*) foi de aproximadamente 38.13 (4919 patentes Não-Emergentes para 129 Emergentes no conjunto de teste, com proporção similar no treino), confirmando a necessidade de técnicas de mitigação, como o uso do *scale_pos_weight* no *XGBoost*.

5.5 Avaliação Comparativa dos Classificadores

Para os algoritmos de classificação *SVM* e *XGBoost*, foram gerados modelos para ambas as análises de Similaridade de Cossenos e de Tanimoto. Os hiperparâmetros foram variados para criar versões com foco na otimização do *F1-score* ou na precisão. Os resultados de desempenho no conjunto de teste (20% dos dados) são apresentados nas Tabelas 1 e 2.

Embora os modelos baseados na similaridade de Tanimoto apresentem alta acurácia global (chegando a 95.66%), este valor deve ser interpretado com cautela devido à preponderância da

Tabela 1: Resultados de classificação para os modelos balanceados, com foco em maximizar a precisão. A precisão e o recall referem-se à classe minoritária (Emergente - ET/True).

Modelo	Acurácia	Precision (ET)	Recall (ET)	F1-Score (Macro)
SVM (Cossenos)	0.8919	1.00	0.00	0.47
SVM (Tanimoto)	0.9479	0.14	0.03	0.51
XGBoost (Cossenos)	0.8956	0.66	0.07	0.54
XGBoost (Tanimoto)	0.9566	0.68	0.06	0.54

Tabela 2: Resultados de classificação para os modelos balanceados, com foco em maximizar o F1-score. A precisão e o recall referem-se à classe minoritária (Emergente - ET/True).

Modelo	Acurácia	Precision (ET)	Recall (ET)	F1-Score (Macro)
SVM (Cossenos)	0.8781	0.49	0.05	0.52
SVM (Tanimoto)	0.9479	0.14	0.03	0.51
XGBoost (Cossenos)	0.8854	0.64	0.13	0.58
XGBoost (Tanimoto)	0.9566	0.71	0.05	0.54

classe Não-Emergente. Portanto, a análise de mérito concentra-se nas métricas da classe minoritária e no *F1-Score* Macro.

Ao observar os modelos otimizados para o *F1-Score* (Tabela 2), o desempenho da Classe Emergente (ET) demonstrou que o *XGBoost* (variante Cossenos) superou o *SVM*. O *Recall* do *XGBoost* foi superior, atingindo **0.13** contra apenas 0.05 do *SVM*, indicando uma maior capacidade em identificar corretamente as patentes emergentes (*True Positives*). A Precisão do *XGBoost* nesta configuração também se mostrou robusta (**0.64** vs 0.49), contribuindo para um *F1-Score* Macro de **0.58**, superior aos 0.52 do *SVM*. Nota-se que o *SVM* focado em precisão (Tabela 1) atingiu 1.00 de precisão, mas com *Recall* nulo, tornando-o ineficaz para a tarefa de descoberta tecnológica.

6 Conclusão

Este estudo apresentou uma abordagem metodológica para a identificação de tecnologias emergentes no setor da construção civil brasileira, integrando modelagem de tópicos (*LDA*) com aprendizado de máquina supervisionado. A principal contribuição reside na proposição de um mecanismo de rotulagem objetivo, que combina similaridade semântica com a persistência tecnológica evidenciada pela criação de novos códigos de classificação (IPC/CPC).

Os experimentos comparativos demonstraram que o algoritmo *XGBoost*, configurado com a métrica de similaridade de Cossenos, superou o *SVM* na tarefa de prospecção. Enquanto métricas como a de Tanimoto resultaram em alta acurácia global, elas falharam em capturar a classe minoritária (tecnologias emergentes). O *XGBoost* mostrou-se mais robusto em lidar com o desbalanceamento severo dos dados, oferecendo o melhor equilíbrio entre precisão e recuperação (*F1-Score*).

Um achado crucial desta pesquisa é a confirmação do impacto da janela temporal na qua-

lidade preditiva. A inclusão de anos recentes (2022-2024), nos quais a janela de verificação de novos IPCs não está completa, introduziu ruído significativo no treinamento. A subsequente remoção desses dados resultou em um aumento substancial na sensibilidade (*Recall*) do modelo, elevando-o para patamares próximos a 0.65. Este resultado valida a premissa de que a identificação de emergência depende intrinsecamente da maturação histórica dos dados, mas também impõe uma limitação de defasagem temporal (*lag*) à metodologia.

Outro ponto que o estudo revela é o valor de uma forma inovadora de rotulagem de patentes. Mesmo diante do desbalanceamento dos dados, que levou a resultados iniciais de modelos insatisfatórios, a linha metodológica proposta apresenta valor significativo ao permitir o trabalho com bases de dados de patentes sem a dependência de um especialista no assunto ou a utilização de métodos simplórios e pouco eficazes na captura do fator de emergência.

Como trabalhos futuros, visando superar as limitações de dados desbalanceados e a dependência temporal, propõe-se a evolução da rotulagem para o nível de *clusters* de patentes, em vez de documentos individuais, para capturar macro-tendências com maior estabilidade. Adicionalmente, a expansão do conjunto de atributos, incluindo histórico dos inventores e métricas de rede, e a aplicação de técnicas de geração de dados sintéticos, como *Generative Adversarial Networks* (GAN) e *SMOTE*, podem ser exploradas para mitigar a escassez de exemplos positivos e aprimorar a capacidade preditiva em cenários de tempo real.

Referências

- Beatto, V. M., & Back, R. B. (2022). Levantamento de patentes tecnológicas que contribuem para a acessibilidade na construção civil. *Revista de Arquitetura IMED*, 11(1), 151–170. <https://doi.org/10.18256/2318-1109.2022.v11i1.4719> [GS Search].
- Choi, Y., Park, S., & Lee, S. (2021). Identifying emerging technologies to envision a future innovation ecosystem: A machine learning approach to patent data. *Scientometrics*, 126(7), 5431–5476. <https://doi.org/10.1007/s11192-021-04001-1> [GS Search].
- Colares, A. C. V., Gouvêa, D. A. P., & Costa, J. S. (2021). Impactos da pandemia do covid-19 no setor de construção civil. *Percursos Acadêmicos*, 11(21), 188–208. <https://doi.org/10.5752/P.2236-0603.2021v11n21p188-208> [GS Search].
- Erdogan, Z., Altuntas, S., & Dereli, T. (2022). Predicting patent quality based on machine learning approach. *IEEE Transactions on Engineering Management*, 71, 3144–3157. <https://doi.org/10.1109/TEM.2022.3207376> [GS Search].
- Kreuchauff, F., & Korzinov, V. (2017). A patent search strategy based on machine learning for the emerging field of service robotics. *Scientometrics*, 111(2), 743–772. <https://doi.org/10.1007/s11192-017-2268-3> [GS Search].
- Kwon, U., & Geum, Y. (2020). Identification of promising inventions considering the quality of knowledge accumulation: A machine learning approach. *Scientometrics*, 125(3), 1877–1897. <https://doi.org/10.1007/s11192-020-03710-3> [GS Search].
- Kyebambe, M. N., Cheng, G., Huang, Y., He, C., & Zhang, Z. (2017). Forecasting emerging technologies: A supervised learning approach through patent analysis. *Technological Forecasting and Social Change*, 125, 236–244. <https://doi.org/10.1016/j.techfore.2017.08.002> [GS Search].

- Lee, C., Kwon, O., Kim, M., & Kwon, D. (2018). Early identification of emerging technologies: A machine learning approach using multiple patent indicators. *Technological Forecasting and Social Change*, 127, 291–303. <https://doi.org/10.1016/j.techfore.2017.10.002> [GS Search].
- Mohammadi, N., Maghsoudi, M., & Soghi, M. (2024). Innovation ecosystems in retail: Uncovering technological trends and collaboration networks through patent mining. *IEEE Access*. <https://doi.org/10.1109/ACCESS.2024.3515290> [GS Search].
- Munaro, M. R., & Tavares, S. F. (2022). A economia circular na construção civil: principais barreiras e oportunidades para a transição do setor. *Revista Tecnologia e Sociedade*, 18(53), 54–71. <https://doi.org/10.3895/rts.v18n53.15726> [GS Search].
- Ranaei, S., & Suominen, A. (2017). Using machine learning approaches to identify emergence: Case of vehicle related patent data. *2017 Portland International Conference on Management of Engineering and Technology (PICMET)*, 1–8. <https://doi.org/10.23919/PICMET.2017.8125290> [GS Search].
- Zhou, Y., Dong, F., Liu, Y., & Ran, L. (2021). A deep learning framework to early identify emerging technologies in large-scale outlier patents: An empirical study of CNC machine tool. *Scientometrics*, 126(2), 969–994. <https://doi.org/10.1007/s11192-020-03797-8> [GS Search].