

Identificação de tecnologias emergentes a partir de dados de patentes usando ML na área da construção civil

Dimitri Prado
Universidade de São Paulo
dimitriprado@usp.br

Luis Henrique Moraes
Universidade de São Paulo
luishmoraes@usp.br

Pedro Oliveira Fernandes
Universidade de São Paulo
pedro.oliveiraf@usp.br

Rodrigo Lyusei Suguimoto
Universidade de São Paulo
rodrigo.lyusei@usp.br

Resumo

A identificação precoce de tecnologias emergentes constitui um desafio para setores consolidados como o da construção civil, onde métodos tradicionais de análise podem ser insuficientes. Este estudo propõe uma metodologia para a identificação automática de tecnologias emergentes no setor da construção civil brasileira, combinando modelagem de tópicos (Latent Dirichlet Allocation - LDA) e aprendizado de máquina (ML) para analisar dados de patentes. Para isso, inicialmente, é realizada a coleta e o pré-processamento de patentes brasileiras da base de dados Lens.org. Em seguida, o modelo LDA é aplicado para identificar temas tecnológicos latentes no corpus de documentos. A "emergência" de cada tema é então quantificada por meio de uma abordagem híbrida, que pondera a probabilidade do tópico em cada patente por uma combinação de suas citações futuras (forward citations), número de inventores e número de reivindicações; essa pontuação híbrida serve como critério para ranquear e identificar os temas tecnológicos de maior potencial. Sendo assim, é possível visualizar as patentes associadas a esses tópicos de destaque, identificando tecnologias emergentes e as tendências futuras do setor.

Palavras-chave: Construção Civil; Patentes; Tecnologias Emergentes; Machine Learning

1 Introdução

A inovação tecnológica é um pilar fundamental para a competitividade e o desenvolvimento sustentável em todos os setores da economia. Para indústrias consolidadas, como a da construção civil, a capacidade de identificar tecnologias emergentes de forma antecipada é um diferencial estratégico crucial, permitindo que as empresas se adaptem, lancem novos produtos e otimizem processos existentes (Choi et al., 2021). A identificação de tendências promissoras possibilita o direcionamento de investimentos em pesquisa e desenvolvimento para áreas com maior potencial de retorno, garantindo uma vantagem competitiva (Lee et al., 2018).

Diante desse desafio, a literatura recente tem explorado modelos computacionais para superar as limitações dos métodos tradicionais. Uma vertente promissora é o uso de modelos de tópicos, como o Latent Dirichlet Allocation (LDA), que permitem descobrir estruturas temáticas latentes em grandes volumes de texto, indo além da simples contagem de palavras-chave e identificando os conceitos tecnológicos subjacentes em um corpus de patentes (Ranaei & Suominen, 2017). Outros estudos argumentam que a identificação de "novidade radical" (Zhou et al., 2021), ou seja, de patentes com pouca similaridade com o conhecimento existente, é um indicador mais preciso de tecnologias verdadeiramente disruptivas. Essa visão é reforçada pela necessidade de avaliar o potencial de uma tecnologia sob múltiplas dimensões, combinando tanto seu impacto tecnológico, frequentemente medido por citações futuras, quanto seu impacto social (Zhou et al., 2021).

Avançando nessa linha, pesquisadores têm proposto a combinação de múltiplos indicadores de patentes para criar uma avaliação mais robusta da qualidade ou do potencial de uma invenção (Erdogan et al., 2022; Lee et al., 2018). A lógica é que características intrínsecas da patente, disponíveis no momento de sua publicação — como o escopo da proteção (número de reivindicações), a intensidade da colaboração (número de inventores) e a ligação com a ciência (referências não-patente) — podem servir como sinais precoces de seu futuro impacto (Lee et al., 2018). Essa abordagem multifatorial busca construir uma métrica de "qualidade" ou "potencial" que seja mais preditiva e menos dependente do tempo do que as citações isoladamente (Erdogan et al., 2022).

Este estudo se insere nesse contexto e propõe um framework metodológico para a identificação de tecnologias emergentes na construção civil brasileira, que integra a modelagem de tópicos com uma métrica híbrida de potencial de emergência. O objetivo é desenvolver um método que não apenas identifique os temas tecnológicos em ascensão, mas que também os classifique com base em um indicador composto, oferecendo uma ferramenta mais robusta e prospectiva para a tomada de decisão estratégica no setor.

2 Fundamentos Teóricos

2.1 Mineração de texto

A mineração de texto refere-se ao conjunto de métodos e técnicas voltados à extração de conhecimento e à identificação de padrões ocultos em documentos textuais não estruturados. Esse processo geralmente envolve etapas como pré-processamento (remoção de ruído, normalização

e tokenização), representação dos textos em modelos numéricos. por exemplo, bag of words ou word embeddings, e, posteriormente, a aplicação de técnicas estatísticas ou de aprendizado de máquina para reduzir a dimensionalidade dos dados e extrair informações relevantes. A redução de dimensionalidade é particularmente importante nesse contexto, uma vez que textos apresentam alta variabilidade e esparsidade, dificultando análises diretas. Ela já foi aplicada em diferentes trabalhos para mapear tendências e identificar inovações emergentes, como em Ranaei & Suominen (Ranaei & Suominen, 2017).

2.2 Latent Dirichlet Allocation

LDA é um modelo probabilístico amplamente utilizado para a extração de tópicos latentes em conjuntos de dados discretos, especialmente em corpora textuais. O modelo assume que cada documento pode ser representado como uma mistura de múltiplos tópicos, enquanto cada tópico é caracterizado por uma distribuição probabilística sobre o vocabulário. Dessa forma, o LDA possibilita identificar estruturas semânticas subjacentes aos textos, permitindo agrupar documentos por similaridade temática sem necessidade de supervisão. A formulação matemática do modelo baseia-se em distribuições de *Dirichlet*, utilizadas tanto para descrever a proporção de tópicos em cada documento quanto para modelar a distribuição de palavras em cada tópico. Essa abordagem tem se consolidado como uma das técnicas mais empregadas em mineração de texto e aprendizado não supervisionado para análise de grandes volumes de dados textuais.

3 Trabalhos Relacionados

A análise de patentes tornou-se uma fonte importante para rastrear tendências tecnológicas e identificar inovações emergentes. Métodos tradicionais são úteis, mas apresentam limitações, como subjetividade, dificuldade em processar grandes volumes de dados e ambiguidade de palavras-chave (Beatto & Back, 2022; Choi et al., 2021; Ranaei & Suominen, 2017). Nesse cenário, a análise de dados e o aprendizado de máquina (ML) vêm transformando a prospecção tecnológica, permitindo uma transição de análises retrospectivas para abordagens preditivas (Erdogan et al., 2022; Kreuchauff & Korzinov, 2017; Lee et al., 2018; Zhou et al., 2021).

Um estudo fortemente relacionado à nossa pesquisa é o de Choi, Park e Lee (Choi et al., 2021). Os autores propõem uma abordagem híbrida que combina percepções de especialistas com dados de patentes para identificar tecnologias promissoras. Eles utilizam aprendizado semi-supervisionado e ativo, aplicando classificadores como Random Forest (RF), Support Vector Machine (SVM) e Extreme Gradient Boosting (XGBoost) no setor de baterias para veículos elétricos. Os resultados mostram que a incorporação do conhecimento de especialistas melhora significativamente a acurácia das previsões. Nosso estudo converge com esse trabalho, pois também empregamos RF e SVM para a classificação de patentes no setor da construção civil.

Outros trabalhos relevantes reforçam essa direção. Lee et al. (Lee et al., 2018) aplicam redes neurais e RF para detectar tecnologias emergentes por meio de indicadores de patentes. Kwon e Geum (Kwon & Geum, 2020) utilizam SVM e RF para identificar invenções promissoras. Já Mohammadi et al. (Mohammadi et al., 2024) exploram redes de colaboração em patentes para identificar tendências tecnológicas. Em conjunto, esses estudos demonstram como técnicas de ML

podem mapear ecossistemas de patentes, identificar tecnologias emergentes e antecipar inovações.

4 Metodologia

A metodologia proposta está estruturada para identificar sistematicamente e analisar tecnologias emergentes no setor da construção civil, utilizando dados de patentes brasileiras e técnicas de aprendizado de máquina. Inspirado na abordagem de Choi (Choi et al., 2021), o processo é dividido em três fases macro: (1) Coleta e Pré-Processamento dos Dados, (2) Modelagem e Classificação de Patentes, e (3) Mapeamento do Ecossistema de Inovação.

4.1 Coleta e Pré-Processamento de Dados

Os dados brutos de patentes foram coletados da base de dados Lens.org, uma plataforma que oferece acesso a uma vasta coleção de patentes globais e artigos acadêmicos. A busca foi realizada por meio de uma query booleana, combinando palavras-chave e termos técnicos relevantes para o domínio da construção civil.

A busca foi direcionada aos campos de título e resumo para garantir a relevância dos documentos. Foi aplicado um filtro geográfico para restringir os resultados a patentes depositadas junto a órgãos brasileiros, como o Instituto Nacional da Propriedade Industrial (INPI). Os dados extraídos (autor, ano de depósito, título, resumo, classificações, etc.) foram exportados em formato de planilha para processamento subsequente. Foram coletadas 50000 patentes, seguindo o limite de nossa base.

A busca será direcionada aos campos de título e resumo para garantir a relevância dos documentos. Será aplicado um filtro geográfico para restringir os resultados a patentes depositadas junto a órgãos brasileiros, como o Instituto Nacional da Propriedade Industrial (INPI). Os dados extraídos (autor, ano de depósito, título, resumo, classificações, etc.) serão exportados em formato de planilha para processamento subsequente.

Os dados não são diretamente utilizáveis pelos algoritmos. Portanto, uma fase de engenharia de atributos será conduzida. A partir de colunas como "nº de inventores", "nº de reivindicações" e do conteúdo textual de "título" e "resumo", serão extraídas e calculadas variáveis preditoras. Inspirado no artigo de referência, estas variáveis podem ser agrupadas em categorias como: características da invenção; características do depositante; características de palavras-chave.

A variável-alvo, que define uma tecnologia como "emergente" ou "promissora", será operacionalizada. Uma abordagem comum, como vista no artigo, é usar um proxy quantitativo, como a frequência de citações futuras (forward citations) para patentes mais antigas, definindo o top 10% como "promissoras". Esta definição será a base para o treinamento inicial do modelo.

4.2 Processamento Analítico e Algoritmos

Nesta fase, algoritmos de aprendizado de máquina serão aplicados para classificar as patentes.

4.2.1 *Abordagem de Aprendizado Híbrida*

Para superar a limitação de ter um pequeno volume de dados previamente classificados (rotulados), será adotada uma abordagem híbrida, combinando aprendizado semi-supervisionado com aprendizado ativo.

- **Aprendizado Semi-Supervisionado:** Um modelo inicial será treinado com um pequeno subconjunto de patentes mais antigas, cujos rótulos ("promissora" vs "não promissora") são conhecidos. Este modelo será então usado para classificar iterativamente o grande volume de dados não rotulados.
- **Aprendizado Ativo:** Para refinar o modelo, o processo permitirá a intervenção de um especialista (ou analista). As patentes que o modelo classificar com menor grau de confiança (ex: probabilidade próxima de 50%) serão selecionadas para rotulagem manual, tornando o conjunto de treinamento mais robusto e preciso a cada iteração.

4.2.2 *Algoritmos de Classificação e Validação*

Para garantir a robustez e mitigar vieses de um único algoritmo, dois modelos de classificação serão desenvolvidos e comparados:

- **Random Forest (RF):** Um algoritmo de ensemble que combina múltiplas árvores de decisão para melhorar a performance e evitar sobreajuste (overfitting).
- **Support Vector Machine (SVM):** Um classificador que busca encontrar o hiperplano ótimo que melhor separa as classes de dados no espaço de atributos.

A performance dos modelos será avaliada utilizando métricas padrão. Dada a natureza desbalanceada do dataset (onde patentes "promissoras" são minoria), além da Acurácia, será dada atenção especial ao F1-Score, que representa a média harmônica entre precisão e revocação (precision e recall), sendo mais adequado para tais cenários. O modelo com melhor performance será então aplicado ao conjunto de patentes mais recentes para identificar as tecnologias emergentes.

4.3 **Análise dos Resultados**

Com as patentes mais recentes devidamente classificadas como "emergentes", será realizada uma análise de co-ocorrência para mapear o ecossistema de inovação. Utilizando os termos-chave extraídos dos títulos e resumos ou os códigos de classificação das patentes (CPC/IPC), será construída uma rede. Nesta rede, os nós podem representar tecnologias (termos-chave), depositantes (empresas/inventores) ou as próprias patentes. E as arestas representarão a força da relação entre os nós (ex: a frequência com que dois termos aparecem juntos nas mesmas patentes promissoras).

A análise da rede permitirá a identificação de clusters (grupos de patentes fortemente conectados), que correspondem aos principais temas tecnológicos emergentes. Além disso, métricas de centralidade na rede ajudarão a identificar os atores-chave (empresas e inventores) que estão liderando a inovação nesses campos. O resultado será um mapa visual do ecossistema futuro, destacando não apenas o quê está emergindo, mas também quem está impulsionando essas inovações, oferecendo uma visão prospectiva e estratégica do setor da construção civil no Brasil.

5 Resultados Parciais

Conforme planejado na metodologia, a coleta de dados foi realizada na base Lens. A busca inicial foi executada utilizando uma query booleana que combinava termos-chave relacionados à construção civil, como "construção", "edificação", "infraestrutura", "cimento", "concreto", e "argamassa", nos campos de título e resumo, com um filtro para documentos com designação no Brasil (INPI). Essa busca inicial resultou em um conjunto bruto de 50.000 patentes.

Por meio de uma análise exploratória com base na Classificação Internacional de Patentes (IPC), validamos as patentes obtidas relacionadas à construção civil. Foi definida uma lista de códigos IPC que representam o núcleo do setor da construção civil, com destaque para a seção "Fixed Constructions", que abrange áreas como edificações (E04), construção de estradas e pontes (E01), e fundações (E02).

O critério de validação estipulou que cada patente no conjunto de dados deveria possuir ao menos um código IPC pertencente a essa lista pré-definida. Os documentos que não atenderam a esse requisito foram considerados falsos positivos e removidos da base. Esse processo de filtragem se mostrou crucial, removendo aproximadamente 33% das patentes coletadas inicialmente, o que evidencia a importância da validação para a qualidade da análise.

6 Discussão e Conclusão

Foi possível construir uma metodologia sólida e baseada em estudos dos trabalhos correlatos para extrair as tendências de tecnologias da área da construção civil, utilizando mineração de texto e análise de citações. Será necessário avaliar os resultados obtidos após aplicar os procedimentos, e identificar possíveis pontos de melhoria a partir da qualidade dos tópicos identificados, comparados com outros artigos que usaram o LDA.

Referências

- Beatto, V. M., & Back, R. B. (2022). Levantamento de patentes tecnológicas que contribuem para a acessibilidade na construção civil. *Revista de Arquitetura IMED*, 11(1), 151–170. <https://doi.org/10.18256/2318-1109.2022.v11i1.4719> [GS Search].
- Choi, Y., Park, S., & Lee, S. (2021). Identifying emerging technologies to envision a future innovation ecosystem: A machine learning approach to patent data. *Scientometrics*, 126(7), 5431–5476. <https://doi.org/10.1007/s11192-021-04001-1> [GS Search].
- Erdogan, Z., Altuntas, S., & Dereli, T. (2022). Predicting patent quality based on machine learning approach. *IEEE Transactions on Engineering Management*, 71, 3144–3157. <https://doi.org/10.1109/TEM.2022.9904033> [GS Search].
- Kreuchau, F., & Korzinov, V. (2017). A patent search strategy based on machine learning for the emerging field of service robotics. *Scientometrics*, 111(2), 743–772. <https://doi.org/10.1007/s11192-017-2268-3> [GS Search].

- Kwon, U., & Geum, Y. (2020). Identification of promising inventions considering the quality of knowledge accumulation: A machine learning approach. *Scientometrics*, 125(3), 1877–1897. <https://doi.org/10.1007/s11192-020-03710-3> [GS Search].
- Lee, C., Kwon, O., Kim, M., & Kwon, D. (2018). Early identification of emerging technologies: A machine learning approach using multiple patent indicators. *Technological Forecasting and Social Change*, 127, 291–303. <https://doi.org/10.1016/j.techfore.2017.11.002> [GS Search].
- Mohammadi, N., Maghsoudi, M., & Soghi, M. (2024). Innovation ecosystems in retail: Uncovering technological trends and collaboration networks through patent mining. *IEEE Access*. <https://doi.org/10.1109/ACCESS.2024.10792909> [GS Search].
- Ranaei, S., & Suominen, A. (2017). Using machine learning approaches to identify emergence: Case of vehicle related patent data. *2017 Portland International Conference on Management of Engineering and Technology (PICMET)*, 1–8. <https://doi.org/10.23919/PICMET.2017.8125290> [GS Search].
- Zhou, Y., Dong, F., Liu, Y., & Ran, L. (2021). A deep learning framework to early identify emerging technologies in large-scale outlier patents: An empirical study of CNC machine tool. *Scientometrics*, 126(2), 969–994. <https://doi.org/10.1007/s11192-020-03797-8> [GS Search].